

Wine Quality Dataset：線性回歸研究與 CRISP-DM 專題報告

撰寫日期：2026-10-08。此文件為研究規劃與可重現實驗程式；模型數字與圖片須實際執行程式後填入，不虛構實驗結果。

一、資料集資格與結論

- Kaggle：https://www.kaggle.com/datasets/yasserh/wine-quality-dataset
- 原始來源 UCI：https://archive.ics.uci.edu/dataset/186/wine+quality
- Kaggle 名次：不適用（N/A）。此連結是 Kaggle Dataset 資料集頁面，不是 Kaggle Competition 競賽頁面，因此沒有官方排行榜、參賽隊伍或提交分數名次。Kaggle 頁面上的 views、downloads、Usability 分數及 Related Notebooks 的獎章，均不是本研究模型的競賽名次。
- Kaggle 下載檔案通常為 WineQT.csv，有 11 個理化輸入特徵、1 個輸出 quality，另可能有 Id 識別碼。Id 不可作為預測特徵。
- 符合 10 至 20 個 features 要求：11 個。注意：特徵選擇後的模型可以只使用部分特徵；資料集原始特徵數仍為 11。
- 品質分數 quality 為離散、有序分數，仍可作為線性回歸的數值目標，但預測可能超出實際分數範圍；報告須交代此限制。
- 單變數線性回歸與多元線性回歸皆可行。Auto Regression 自迴歸依賴時間順序，本資料非時間序列，不建議使用。

二、欄位與角色

欄位	角色	說明
fixed acidity	X	固定酸度
volatile acidity	X	揮發性酸度
citric acid	X	檸檬酸
residual sugar	X	殘糖
chlorides	X	氯化物
free sulfur dioxide	X	游離二氧化硫
total sulfur dioxide	X	總二氧化硫
density	X	密度
pH	X	酸鹼值
sulphates	X	硫酸鹽
alcohol	X	酒精濃度
quality	y	品質評分（目標）
Id（若存在）	排除	索引／識別碼，避免假相關

UCI 提供紅、白葡萄酒原始資料集（紅酒 1599 筆、白酒 4898 筆）；本次指定的 Kaggle WineQT.csv 為其衍生版本，資料筆數須以實際下載 CSV 為準，不應直接將 UCI 白酒的 4898 筆視為本 Kaggle 檔案筆數。

三、研究目的與假設

研究問題：能否依據葡萄酒的理化測量數值預測其感官品質分數？特徵篩選能否在減少輸入維度的同時維持預測準確性？

- H1：多元線性回歸優於只用 alcohol 的單變數線性回歸。
- H2：以訓練集進行統計特徵篩選後，能以較少變數得到具競爭力的測試誤差。
- 注意：H1、H2 為待驗證假設，不是研究結論。

四、CRISP-DM 六大階段

1. Business Understanding（商業理解）

酒商或品管單位希望在感官品評之前，根據可測得的化學指標進行初步品質估計，協助品質管理與分析。成功準則為低 MAE / RMSE、合理 R^2 ，以及可解釋且可使用的預測區間。不以此模型取代專業品酒評估。

2. Data Understanding（資料理解）

使用 head()、info()、describe()、缺失值檢查、重複值分析、品質分數分布、特徵相關性熱圖。核實實際 CSV 的筆數、欄位、資料型態與 quality 不均衡現象。檢查同一欄位極端值及共線性。

3. Data Preparation（資料準備）

移除 Id，設定 quality 為 y、其餘 11 欄為 X。以固定 random_state 進行 80/20 訓練與測試切分。不得在切分前依全體資料選特徵或標準化，避免資料洩漏。特徵篩選只在訓練集進行。若有缺失值，須先於訓練資料上擬合補值器（範例採 sklearn Pipeline）。重複樣本需檢查並交代處理策略，避免同一紀錄同時出現在訓練和測試資料。

4. Modeling（模型建立）

- ．模型 A：Simple Linear Regression；只用 alcohol 作為自變數。
- ．模型 B：Multiple Linear Regression；11 個理化特徵全部納入。
- ．模型 C：Feature Selection + Multiple Linear Regression；訓練集以 SelectKBest(f_regression, k=5) 選出 5 個特徵後建模。
- ．迴歸模型公式： $\text{quality_hat} = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$ 。
- ．k=5 是事先指定的可重現展示設定，不代表實證最優；若要調整 k，需在訓練資料內執行交叉驗證，不可偷看測試集。

5. Evaluation（模型評估）

評估保留測試集上的 MAE、MSE、RMSE、 R^2 ，搭配實際值與預測值散佈圖、殘差圖、95% 預測區間圖、預測區間涵蓋率與平均寬度。比較三個模型；特徵數與解釋力也是評估指標。對單筆未來葡萄酒分數，預測區間（Prediction Interval）比均值信賴區間（Confidence Interval）更符合題意；前者考慮單筆資料的不可預測變動，因此通常更寬。OLS 的經典區間假設包括線性形式、誤差常態與同質變異等，需檢視殘差。若區間超出 0 - 10 需在報告中說明。

6. Deployment（部署）

將表現合宜的特徵選擇器與迴歸模型保存為 joblib Pipeline，未來可透過 Python 腳本、Streamlit 或 FastAPI 輸入理化指標得到預估品質分數。部署後需記錄資料版本、特徵名稱與模型版本，監測新資料分布漂移及預測誤差；如需部署預測區間，也須保存相對應的統計模型及特徵順序。

五、實作流程與完整 Python 程式

環境（本機或 Google Colab）：pip install pandas numpy matplotlib seaborn scikit-learn statsmodels joblib kagglehub。程式會使用 kagglehub 自動下載指定 Kaggle 資料集；若執行目錄已有 WineQT.csv，則優先使用本地檔案。獨立可執行版本為 5115056030_hw2.py，可在 Colab 上先執行安裝指令，再上傳並執行該檔案。

程式產出

- ．01_correlation_heatmap.png：相關係數熱圖。
- ．02_model_metrics.csv：A、B、C 三個模型的 MAE / MSE / RMSE / R^2 。
- ．03_prediction_interval.png：實際品質 vs. 預測品質 + 95% Prediction Interval（題目必要）。
- ．04_actual_vs_predicted.png：預測值與真實值散佈圖。
- ．三份 .joblib：訓練好的 pipeline。

避免誤解：03_prediction_interval.png 需下載 CSV 執行後才會生成；此份 Markdown 本身沒有宣稱已實際完成模型測試。程式使用 OLS 殘差估計傳統、模型假設成立下的參數式預測區間；區間涵蓋率仍需實際驗證。


六、結果表格（執行後填寫）



模型	特徵數	MAE	MSE	RMSE	R ²
A：單變數 alcohol	1	0.5265	0.4175	0.6462	0.2497
B：全部特徵	11	0.4773	0.3800	0.6165	0.3171
C：SelectKBest top 5	5	0.4834	0.3856	0.6210	0.3071

本次執行結果顯示，全部 11 個特徵的模型表現最佳，RMSE 為 0.6165、 R^2 為 0.3171；相較只使用 alcohol 的基準模型，RMSE 下降約 4.6%， R^2 由 0.2497 提升至 0.3171。SelectKBest 選出的 5 個特徵為 volatile_acidity、citric_acid、density、sulphates、alcohol，其 RMSE 為 0.6210，僅比全部特徵模型高 0.0045，表示使用較少變數仍保有接近的預測能力。模型 C 的 95% 預測區間涵蓋率為 0.9520，平均區間寬度為 2.5916。由於品質分數集中在 5 和 6，且樣本量為 1,143 筆，線性模型的 R^2 仍有限；本結果適合作為可解釋基準，不宜視為取代感官品評的完整模型。

以上指標來自固定 random_state=42 的 80/20 保留測試集；測試集只用於最後評估，沒有用來選擇特徵或調整模型。

實際圖表





七、AI 輔助研究

GPT 輔助內容

本報告使用 GPT 協助整理 CRISP-DM 架構、設計三組線性回歸比較、撰寫 KaggleHub 可重現下載程式、規劃 SelectKBest 特徵選擇，以及建立 OLS 95% 預測區間。所有模型指標與圖表均由 5115056030_hw2.py 實際執行產生；GPT 未直接捏造實驗數字。GPT 對話紀錄應另以 pdfCrowd 或瀏覽器列印功能匯出 PDF，並與本報告一併繳交。

GPT 對話摘要

本次對話先針對既有 Wine Quality 報告檢查作業要求，確認資料集必須具備 10 至 20 個特徵，並納入 CRISP-DM、特徵選擇、模型評估、預測圖與區間估計。接著將原本要求手動放置 WineQT.csv 的程式，改為使用 `kagglehub.dataset_download("yasserh/wine-quality-dataset")` 自動下載，並保留本地 CSV 作為 fallback。環境處理過程中，GPT 協助建立 Python 3.12 的 .venv，安裝 KaggleHub、pandas、NumPy、Matplotlib、Seaborn、scikit-learn、statsmodels 與 joblib。完成環境後，GPT 建立獨立的 5115056030_hw2.py 與 Colab Notebook，實際下載 1,143 筆資料並執行三個模型。實驗結果顯示全部 11 特徵模型 RMSE 最低為 0.6165，SelectKBest 前 5 特徵模型的 RMSE 為 0.6210，95% 預測區間涵蓋率為 0.9520。最後，GPT 將結果、圖表、程式與報告整理成 PDF 與 ZIP。這段摘要描述的是實際協作與執行流程，完整對話紀錄另附 ilovepdf_merged.pdf。

NotebookLM 摘要

本節整理 NotebookLM 針對下列來源進行交叉閱讀後的研究重點。正式繳交時，應將 NotebookLM 的來源畫面或匯出紀錄一併放入附件，以證明研究流程。

- Kaggle 原資料：<https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>
- UCI 資料與研究說明：<https://archive.ics.uci.edu/dataset/186/wine+quality>
- Kaggle 同資料之模型比較範例：<https://www.kaggle.com/code/yasserh/wine-quality-prediction-comparing-top-ml-models>
- 原始論文：Cortez et al. (2009), *Modeling wine preferences by data mining from physicochemical properties* (可從 UCI 頁面連結進入)

研究來源與問題脈絡

NotebookLM 整合 Kaggle 資料集頁面、UCI Wine Quality 說明、相關 Kaggle Notebook 與 Cortez 等人提出的原始研究。這些來源共同指出，葡萄酒品質預測是以理化測量值推估感官評分的典型資料科學問題；資料既可以視為品質分數的迴歸，也可以依門檻轉為分類。研究的實務價值在於，化學測量通常比完整感官品評更容易標準化，因此可用於早期篩選與品質管理。

來源共同發現

觀察面向	NotebookLM 整理出的重點
輸入資料	固定酸度、揮發性酸度、檸檬酸、殘糖、氯化物、二氧化硫、密度、pH、硫酸鹽與酒精等 11 個特徵
目標變數	感官品質分數，屬於離散且有序的評分
資料特性	品質分數分布不均，普通品質樣本明顯多於極高或極低品質樣本
建模策略	先建立簡單基準，再比較多元線性模型、正規化模型與非線性集成模型
評估原則	使用保留測試集或交叉驗證，並同時觀察誤差、解釋力與模型假設

方法建議與本研究對照

線性回歸的優點是係數容易解釋，可以清楚討論不同化學特徵與品質預測之間的關係；但品質分數的離散性、偏態分布與可能存在的異質變異，會限制線性模型的預測能力。因此，本研究先以只使用 alcohol 的模型建立基準，再比較全部 11 個特徵的多元線性回歸，最後用只在訓練集執行的 SelectKBest 選出 5 個特徵。結果顯示，全部特徵模型的 RMSE 為 0.6165、 R^2 為 0.3171；前 5 特徵模型的 RMSE 為 0.6210、 R^2 為 0.3071，表示減少變數後仍保留大部分預測能力。這與來源所建議的「基準模型、特徵處理、保留測試集評估」研究脈絡一致。

研究限制與延伸方向

NotebookLM

的資料比較也提醒，本研究的線性回歸應視為可解釋的基準，而非唯一或最終解法。後續可在訓練資料內使用 K-fold cross-validation 比較 Ridge、Random Forest、Gradient Boosting 或 XGBoost，並檢查殘差常態性、線性關係與變異數同質性。由於本資料不是時間序列，不適合使用 Auto Regression；若改做分類，則應改用適合有序或不平衡類別的評估指標，例如 macro-F1、balanced accuracy 或 ordinal classification 指標。

主流或更優解法比較

Kaggle 上常見的比較會加入 Random Forest、Gradient Boosting、XGBoost 或其他集成模型。這些非線性模型可能捕捉特徵交互作用，預測準確度通常有機會高於線性回歸，但可解釋性與預測區間呈現較複雜。本作業選擇線性回歸作為透明基準，並以 SelectKBest 降低變數數量；若要延伸，可在訓練資料內使用 K-fold cross-validation 比較 Ridge、Random Forest 與 Gradient Boosting，再以獨立測試集做最後評估。

Kaggle 名次與本研究結果

項目	結果
Kaggle Competition 名次	N/A：資料集頁面沒有競賽排行榜

項目	結果
Kaggle Dataset 頁面	Wine Quality Dataset (Yasser H.)
本研究最佳模型	全部 11 特徵 Multiple Linear Regression
本研究測試集 RMSE	0.6165
本研究測試集 R^2	0.3171

因此，本作業以測試集評估指標作為模型成果，而不虛構不存在的 Kaggle 排名。若老師要求必須呈現競賽名次，應改用具有 leaderboard 與 Submit to Competition 的 Kaggle Competition 資料集；本資料集則可在報告中以「Kaggle 名次不適用」完整交代。

八、繳交檢查清單

- . [x] 指定 Kaggle 公開資料集與原始來源
- . [x] 11 個 features 的確認與欄位解釋
- . [x] CRISP-DM 六階段
- . [x] 特徵選擇、三種回歸模型、評估方案與完整繪圖程式
- . [x] 使用 KaggleHub 實際下載 WineQT.csv 並執行
- . [x] 將 02_model_metrics.csv 的真實指標填回第六節
- . [x] 產生 03_prediction_interval.png 與其他圖表
- . [x] 建立可在 Google Colab 執行的 5115056030_hw2.py
- . [] 如老師要求，實際使用 NotebookLM 研究並保存來源／引用截圖

參考資料

- . Kaggle, Wine Quality Dataset. <https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>
- . UCI Machine Learning Repository, Wine Quality. <https://archive.ics.uci.edu/dataset/186/wine+quality>
- . Yasser H., Wine Quality Prediction — Comparing Top ML Models.
<https://www.kaggle.com/code/yasserh/wine-quality-prediction-comparing-top-ml-models>
- . Cortez, P., et al. (2009). *Modeling wine preferences by data mining from physicochemical properties*. Decision Support Systems.

GPT 輔助內容

本次對話與葡萄酒品質資料集研究報告

日期：2026-10-08

對話紀錄（本次請求與回覆摘要）

使用者：評估 <https://www.kaggle.com/datasets/yasserh/wine-quality-dataset> 是否符合 10~20 個特徵，使用線性回歸並包含特徵選擇、模型評估、預測圖與信賴／預測區間，涵蓋 CRISP-DM 六階段；整理 Markdown，並將對話存成 PDF。

助理：確認指定資料具有 11 個理化輸入特徵，quality 是目標變數，Id 不是有效特徵。建議比較單一與多元線性回歸及特徵選擇版本，提供具 95% 預測區間繪圖的完整程式。實際實驗指標和圖片必須執行程式後才能填寫。

註：本 PDF 保存這次任務的對話摘要和完整研究報告，不是平台的逐字對話匯出。

Wine Quality Dataset：線性回歸研究與 CRISP-DM 專題報告

撰寫日期：2026-10-08。此文件為研究規劃與可重現實驗程式；模型數字與圖片須實際執行程式後填入，不虛構實驗結果。

一、資料集資格與結論

- Kaggle：<https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>
- 原始來源 UCI：<https://archive.ics.uci.edu/dataset/186/wine+quality>
- Kaggle 下載檔案通常為 WineQT.csv，有 11 個理化輸入特徵、1 個輸出 quality，另可能有 Id 識別碼。Id 不可作為預測特徵。
- **符合 10 至 20 個 features 要求：11 個。**注意：特徵選擇後的模型可以只使用部分特徵；資料集原始特徵數仍為 11。
- 品質分數 quality 為離散、有序分數，仍可作為線性回歸的數值目標，但預測可能超出實際分數範圍；報告須交代此限制。

- 單變數線性回歸與多元線性回歸皆可行。Auto Regression 自迴歸依賴時間順序，本資料非時間序列，不建議使用。

二、欄位與角色

欄位	角色	說明
fixed acidity	X	固定酸度
volatile acidity	X	揮發性酸度
citric acid	X	檸檬酸
residual sugar	X	殘糖
chlorides	X	氯化物
free sulfur dioxide	X	游離二氧化硫
total sulfur dioxide	X	總二氧化硫
density	X	密度
pH	X	酸鹼值
sulphates	X	硫酸鹽
alcohol	X	酒精濃度
quality	y	品質評分（目標）
Id（若存在）	排除	索引／識別碼，避免假相關

UCI 提供紅、白葡萄酒原始資料集（紅酒 1599 筆、白酒 4898 筆）；**本次指定的 Kaggle WineQT.csv 為其衍生版本，資料筆數須以實際下載 CSV 為準，不應直接將 UCI 白酒的 4898 筆視為本 Kaggle 檔案筆數。**

三、研究目的與假設

研究問題：能否依據葡萄酒的理化測量數值預測其感官品質分數？特徵篩選能否在減少輸入維度的同時維持預測準確性？

- H1：多元線性回歸優於只用 alcohol 的單變數線性回歸。
- H2：以訓練集進行統計特徵篩選後，能以較少變數得到具競爭力的測試誤差。
- 注意：H1、H2 為**待驗證假設**，不是研究結論。

四、CRISP-DM 六大階段

1. Business Understanding（商業理解）

酒商或品管單位希望在感官品評之前，根據可測得的化學指標進行初步品質估計，協助品質管理與分析。成功準則為低 MAE / RMSE、合理 R^2 ，以及可解釋且可使用的預測區間。不以此模型取代專業品酒評估。

2. Data Understanding (資料理解)

使用 `head()`、`info()`、`describe()`、缺失值檢查、重複值分析、品質分數分布、特徵相關性熱圖。核實實際 CSV 的筆數、欄位、資料型態與 `quality` 不均衡現象。檢查同一欄位極端值及共線性。

3. Data Preparation (資料準備)

移除 `Id`，設定 `quality` 為 `y`、其餘 11 欄為 `X`。以固定 `random_state` 進行 80/20 訓練與測試切分。不得在切分前依全體資料選特徵或標準化，避免資料洩漏。特徵篩選只在訓練集進行。若有缺失值，須先於訓練資料上擬合補值器（範例採 `sklearn Pipeline`）。重複樣本需檢查並交代處理策略，避免同一紀錄同時出現在訓練和測試資料。

4. Modeling (模型建立)

- 模型 A：Simple Linear Regression；只用 `alcohol` 作為自變數。
- 模型 B：Multiple Linear Regression；11 個理化特徵全部納入。
- 模型 C：Feature Selection + Multiple Linear Regression；訓練集以 `SelectKBest(f_regression, k=5)` 選出 5 個特徵後建模。
- 迴歸模型公式： $\text{quality_hat} = \beta_0 + \beta_1 \times x_1 + \dots + \beta_p \times x_p$ 。
- `k=5` 是事先指定的可重現展示設定，不代表實證最優；若要調整 `k`，需在訓練資料內執行交叉驗證，不可偷看測試集。

5. Evaluation (模型評估)

評估保留測試集上的 `MAE`、`MSE`、`RMSE`、 R^2 ，搭配實際值與預測值散佈圖、殘差圖、95% 預測區間圖、預測區間涵蓋率與平均寬度。比較三個模型；特徵數與解釋力也是評估指標。對單筆未來葡萄酒分數，**預測區間 (Prediction Interval) 比均值信賴區間 (Confidence Interval) 更符合題意**；前者考慮單筆資料的不可預測變動，因此通常更寬。OLS 的經典區間假設包括線性形式、誤差常態與同質變異等，需檢視殘差。若區間超出 0-10 需在報告中說明。

6. Deployment (部署)

將表現合宜的特徵選擇器與迴歸模型保存為 `joblib Pipeline`，未來可透過 Python 腳本、`Streamlit` 或 `FastAPI` 輸入理化指標得到預估品質分數。部署後需記錄資料版本、特徵名稱與模型版本，監測新資料分布漂移及預測誤差；如需部署預測區間，也須保存相對應的統計模型及特徵順序。

五、實作流程與完整 Python 程式

環境：pip install pandas numpy matplotlib seaborn scikit-learn statsmodels joblib。將 Kaggle 下載的 WineQT.csv 放在程式執行目錄。程式不需要額外資料集。

```
from pathlib import Path
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import joblib
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.feature_selection import SelectKBest, f_regression
from sklearn.linear_model import LinearRegression
from sklearn.impute import SimpleImputer
from sklearn.pipeline import Pipeline
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

PATH = Path("WineQT.csv")
if not PATH.exists():
    raise FileNotFoundError("請從指定 Kaggle 網址下載 WineQT.csv 並放在同一資料夾")

df = pd.read_csv(PATH)
df.columns = df.columns.str.strip().str.replace(" ", "_", regex=False)
print("資料維度: ", df.shape)
print("欄位: ", df.columns.tolist())
print("缺失值: \n", df.isna().sum())
print("quality 分布: \n", df["quality"].value_counts().sort_index())

# 此 Kaggle CSV 可能有 Id; 明確移除識別碼。
df = df.drop(columns=["Id", "id"], errors="ignore")
X = df.drop(columns=["quality"])
y = df["quality"]
assert X.shape[1] == 11, f"預期 11 個輸入特徵, 實際 {X.shape[1]}。請檢查檔案。"
assert "alcohol" in X.columns

plt.figure(figsize=(10, 8))
sns.heatmap(df.corr(numeric_only=True), cmap="coolwarm", center=0)
plt.title("Feature correlation")
plt.tight_layout()
plt.savefig("01_correlation_heatmap.png", dpi=180)
plt.close()

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=42
)

models = {
    "A_Simple_alcohol": (["alcohol"], Pipeline([
        ("imputer", SimpleImputer(strategy="median")),
        ("reg", LinearRegression())
    ])),
    "B_Multiple_all11": (list(X.columns), Pipeline([
        ("imputer", SimpleImputer(strategy="median")),
        ("reg", LinearRegression())
    ])),
    "C_Selected_top5": (list(X.columns), Pipeline([
        ("imputer", SimpleImputer(strategy="median")),
        ("select", SelectKBest(score_func=f_regression, k=5)),
        ("reg", LinearRegression())
    ]))
}

results = []
for name, (columns, model) in models.items():
    model.fit(X_train[columns], y_train)
    prediction = model.predict(X_test[columns])
    mse = mean_squared_error(y_test, prediction)
    selected_cols = columns
    if name == "C_Selected_top5":
        selected_cols = X_train[columns].columns[
            model.named_steps["select"].get_support()
        ].tolist()
    results.append({
        "Model": name,
        "Features": " ".join(selected_cols),
    })
```

```

        "N_features": len(selected_cols),
        "MAE": mean_absolute_error(y_test, prediction),
        "MSE": mse,
        "RMSE": np.sqrt(mse),
        "R2": r2_score(y_test, prediction)
    })
    joblib.dump(model, f"{name}.joblib")

metrics = pd.DataFrame(results).sort_values("RMSE")
print(metrics.to_string(index=False))
metrics.to_csv("02_model_metrics.csv", index=False, encoding="utf-8-sig")

# 以事先指定的模型 C 製作 95% 單筆預測區間（不依測試成績挑模型）。
selected_pipe = models["C_Selected_top5"][1]
selector = selected_pipe.named_steps["select"]
selected_names = X_train.columns[selector.get_support()].tolist()
imputer = selected_pipe.named_steps["imputer"]
tr_array = imputer.transform(X_train)
te_array = imputer.transform(X_test)
tr_selected = selector.transform(tr_array)
te_selected = selector.transform(te_array)

# 在訓練集上以相同欄位重新擬合 OLS，取得統計推論的預測區間。
X_ols_train = sm.add_constant(tr_selected, has_constant="add")
X_ols_test = sm.add_constant(te_selected, has_constant="add")
ols = sm.OLS(y_train.to_numpy(), X_ols_train).fit()
frame = ols.get_prediction(X_ols_test).summary_frame(alpha=0.05)

# 排序只是為了使圖易讀，區間仍是對每一個測試樣本的估計。
idx = np.argsort(frame["mean"].to_numpy())
actual = y_test.to_numpy()[idx]
pred = frame["mean"].to_numpy()[idx]
lower = frame["obs_ci_lower"].to_numpy()[idx]
upper = frame["obs_ci_upper"].to_numpy()[idx]
xaxis = np.arange(len(idx))

plt.figure(figsize=(13, 6))
plt.fill_between(xaxis, lower, upper, alpha=0.28, label="95% prediction interval")
plt.plot(xaxis, pred, linewidth=1.6, label="Predicted quality")
plt.scatter(xaxis, actual, s=12, alpha=0.6, label="Actual quality")
plt.xlabel("Test samples (sorted by prediction)")
plt.ylabel("Quality score")
plt.title("Selected Linear Regression: Prediction with 95% PI")
plt.legend()
plt.tight_layout()
plt.savefig("03_prediction_interval.png", dpi=200)
plt.close()

plt.figure(figsize=(7, 6))
plt.scatter(y_test, frame["mean"], alpha=0.5)
lims = [min(y_test.min(), frame["mean"].min()),
        max(y_test.max(), frame["mean"].max())]
plt.plot(lims, lims, "r--", label="Ideal")
plt.xlabel("Actual quality")
plt.ylabel("Predicted quality")
plt.title("Actual vs Predicted (Selected Linear Regression)")
plt.legend()
plt.tight_layout()
plt.savefig("04_actual_vs_predicted.png", dpi=200)
plt.close()

coverage = np.mean((y_test.to_numpy() >= frame["obs_ci_lower"].to_numpy()) &
                  (y_test.to_numpy() <= frame["obs_ci_upper"].to_numpy()))
print("模型 C 選入特徵：", selected_names)
print("95% PI 實際涵蓋率：", round(coverage, 4))
print("PI 平均寬度：", round(np.mean(upper-lower), 4))
print("輸出圖片：01_correlation_heatmap.png、03_prediction_interval.png、04_actual_vs_predicted.png")

```

程式產出

- 01_correlation_heatmap.png：相關係數熱圖。
- 02_model_metrics.csv：A、B、C 三個模型的 MAE / MSE / RMSE / R^2 。
- 03_prediction_interval.png：實際品質 vs. 預測品質 + 95% Prediction Interval（題目必要）。
- 04_actual_vs_predicted.png：預測值與真實值散佈圖。

5. 三份 .joblib：訓練好的 pipeline。

避免誤解： 03_prediction_interval.png 需下載 CSV 執行後才會生成；此份 Markdown 本身沒有宣稱已實際完成模型測試。程式使用 OLS 殘差估計傳統、模型假設成立下的參數式預測區間；區間涵蓋率仍需實際驗證。

六、結果表格（執行後填寫）

模型	特徵數	MAE	MSE	RMSE	R ²
A：單變數 alcohol	1	待執行	待執行	待執行	待執行
B：全部特徵	11	待執行	待執行	待執行	待執行
C：SelectKBest top 5	5	待執行	待執行	待執行	待執行

結果分析建議：比較 B、C 相對 A 的 RMSE 改善，討論使用較少欄位時預測表現是否下降；檢查殘差是否存在異質變異、品質極端分數是否較容易預測失準；報告實際測試集 95% 區間涵蓋率。不要直接把測試集評估成績當作調參依據。

七、NotebookLM 相關研究（供自行整理來源，非聲稱已使用 NotebookLM）

建議匯入下列來源再讓 NotebookLM 做交叉比對：

- Kaggle 原資料：<https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>
- UCI 資料與研究說明：<https://archive.ics.uci.edu/dataset/186/wine+quality>
- Kaggle 同資料之模型比較範例：<https://www.kaggle.com/code/yasserh/wine-quality-prediction-comparing-top-ml-models>
- 原始論文：Cortez et al. (2009), Modeling wine preferences by data mining from physicochemical properties（可從 UCI 頁面連結進入）

100 字以上研究摘要草稿（請透過 NotebookLM 親自核對來源後修改）： 葡萄酒品質預測經常使用化學測量值作為輸入，並將感官品質評分作為模型輸出。UCI Wine Quality 提供固定酸度、揮發性酸度、檸檬酸、殘糖、氯化物、二氧化硫、密度、pH、硫酸鹽與酒精等十一個特徵，既適合迴歸，也能轉為分類問題。針對課程要求，可先建立單變數線性回歸作為基準，再使用所有輸入欄位建立多元線性回歸，最後加入統計特徵選擇，觀察變數數量與預測誤差之間的取舍。模型應使用保留測試集評估 MAE、RMSE 與 R²，並以單筆預測區間呈現不確定性。由於品質分數分布不均、結果屬有序離散分數，線性回歸仍有假設與表現限制，因此須搭配殘差檢查與區間涵蓋率評估。

八、繳交檢查清單



指定 Kaggle 公開資料集與原始來源



11 個 features 的確認與欄位解釋



CRISP-DM 六階段



特徵選擇、三種回歸模型、評估方案與完整繪圖程式



本機下載 WineQT.csv 並實際執行



將 02_model_metrics.csv 的真實指標填回第六節



在最終報告插入 03_prediction_interval.png 與其他圖表



如老師要求，實際使用 NotebookLM 研究並保存來源／引用截圖

參考資料

1. Kaggle, Wine Quality Dataset. <https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>
2. UCI Machine Learning Repository, Wine Quality. <https://archive.ics.uci.edu/dataset/186/wine+quality>
3. Yasser H., Wine Quality Prediction — Comparing Top ML Models. <https://www.kaggle.com/code/yasserh/wine-quality-prediction-comparing-top-ml-models>
4. Cortez, P., et al. (2009). Modeling wine preferences by data mining from physicochemical properties. Decision Support Systems.

NotebookLM 摘要

本報告彙整當前網路上與學術界針對葡萄酒品質預測（Wine Quality Prediction）之主流實作路徑。目前網路上的解法多以 **UCI Wine Quality Dataset** 為基礎，將 11 項理化特徵（如酒精濃度、揮發性酸度、pH 值與硫酸鹽等）作為輸入變數，並區分為「回歸連續預測」與「品質等級分類」兩種方向。在**資料預處理**方面，常見做法包含特徵標準化（StandardScaler）與針對極端品質樣本進行重採樣（如 SMOTE）以解決類別不平衡問題。在**特徵選擇**上，主流透過遞歸特徵消除（RFE）、主成分分析（PCA）或相關係數熱力圖，選出影響最顯著的理化指標。在**模型選用**上，除基礎線性回歸外，多數網路解法亦延伸至非線性機器學習模型（如隨機森林 RF、支持向量機 SVM 與 XGBoost），實驗結果普遍顯示非線性模型與特徵篩選結合後能大幅提升預測準率與模型穩定度。

核心發現與主題整理

- 多元建模視角**：網路上解法涵蓋傳統線性回歸（連續得分預測）與機器學習分類器（將品質分為高/中/低等級），滿足不同場景的需求。
- 特徵篩選效益顯著**：根據 **PMC** 與 **SciTePress** 發表的近期研究，透過 RFE 或 PCA 適當剔除低相關性特徵，能顯著降低噪訊並增強 SVM 與隨機森林等模型的預測穩定度。
- 資料不平衡處理**：根據 **arXiv** 與 **RPubs** 的專案經驗，極端高低品質葡萄酒樣本稀少，採用特徵縮放與重採樣技術能有效提升模型對關鍵樣本的辨識力。