

# Wine Quality Dataset：線性回歸研究與 CRISP-DM 專題報告

撰寫日期：2026-10-08。此文件為研究規劃與可重現實驗程式；模型數字與圖片須實際執行程式後填入，不虛構實驗結果。

## 一、資料集資格與結論

- Kaggle：<https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>
- 原始來源 UCI：<https://archive.ics.uci.edu/dataset/186/wine+quality>
- Kaggle 下載檔案通常為 WineQT.csv，有 11 個理化輸入特徵、1 個輸出 quality，另可能有 Id 識別碼。Id 不可作為預測特徵。
- 符合 10 至 20 個 features 要求：11 個。注意：特徵選擇後的模型可以只使用部分特徵；資料集原始特徵數仍為 11。
- 品質分數 quality 為離散、有序分數，仍可作為線性回歸的數值目標，但預測可能超出實際分數範圍；報告須交代此限制。
- 單變數線性回歸與多元線性回歸皆可行。Auto Regression 自迴歸依賴時間順序，本資料非時間序列，不建議使用。

## 二、欄位與角色

| 欄位                   | 角色 | 說明           |
|----------------------|----|--------------|
| fixed acidity        | X  | 固定酸度         |
| volatile acidity     | X  | 揮發性酸度        |
| citric acid          | X  | 檸檬酸          |
| residual sugar       | X  | 殘糖           |
| chlorides            | X  | 氯化物          |
| free sulfur dioxide  | X  | 游離二氧化硫       |
| total sulfur dioxide | X  | 總二氧化硫        |
| density              | X  | 密度           |
| pH                   | X  | 酸鹼值          |
| sulphates            | X  | 硫酸鹽          |
| alcohol              | X  | 酒精濃度         |
| quality              | y  | 品質評分（目標）     |
| Id（若存在）              | 排除 | 索引／識別碼，避免假相關 |

UCI 提供紅、白葡萄酒原始資料集（紅酒 1599 筆、白酒 4898 筆）；本次指定的 Kaggle WineQT.csv 為其衍生版本，資料筆數須以實際下載 CSV 為準，不應直接將 UCI 白酒的 4898 筆視為本 Kaggle 檔案筆數。

## 三、研究目的與假設

研究問題：能否依據葡萄酒的理化測量數值預測其感官品質分數？特徵篩選能否在減少輸入維度的同時維持預測準確性？

- H1：多元線性回歸優於只用 alcohol 的單變數線性回歸。
- H2：以訓練集進行統計特徵篩選後，能以較少變數得到具競爭力的測試誤差。
- 注意：H1、H2 為待驗證假設，不是研究結論。

## 四、CRISP-DM 六大階段

### 1. Business Understanding（商業理解）

酒商或品管單位希望在感官品評之前，根據可測得的化學指標進行初步品質估計，協助品質管理與分析。成功準則為低 MAE / RMSE、合理  $R^2$ ，以及可解釋且可使用的預測區間。不以此模型取代專業品酒評估。

## 2. Data Understanding（資料理解）

使用 head()、info()、describe()、缺失值檢查、重複值分析、品質分數分布、特徵相關性熱圖。核實實際 CSV 的筆數、欄位、資料型態與 quality 不均衡現象。檢查同一欄位極端值及共線性。

## 3. Data Preparation（資料準備）

移除 Id，設定 quality 為 y、其餘 11 欄為 X。以固定 random\_state 進行 80/20 訓練與測試切分。不得在切分前依全體資料選特徵或標準化，避免資料洩漏。特徵篩選只在訓練集進行。若有缺失值，須先於訓練資料上擬合補值器（範例採 sklearn Pipeline）。重複樣本需檢查並交代處理策略，避免同一紀錄同時出現在訓練和測試資料。

## 4. Modeling（模型建立）

- ．模型 A：Simple Linear Regression；只用 alcohol 作為自變數。
- ．模型 B：Multiple Linear Regression；11 個理化特徵全部納入。
- ．模型 C：Feature Selection + Multiple Linear Regression；訓練集以 SelectKBest(f\_regression, k=5) 選出 5 個特徵後建模。
- ．迴歸模型公式： $\text{quality\_hat} = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$ 。
- ．k=5 是事先指定的可重現展示設定，不代表實證最優；若要調整 k，需在訓練資料內執行交叉驗證，不可偷看測試集。

## 5. Evaluation（模型評估）

評估保留測試集上的 MAE、MSE、RMSE、 $R^2$ ，搭配實際值與預測值散佈圖、殘差圖、95% 預測區間圖、預測區間涵蓋率與平均寬度。比較三個模型；特徵數與解釋力也是評估指標。對單筆未來葡萄酒分數，預測區間（Prediction Interval）比均值信賴區間（Confidence Interval）更符合題意；前者考慮單筆資料的不可預測變動，因此通常更寬。OLS 的經典區間假設包括線性形式、誤差常態與同質變異等，需檢視殘差。若區間超出 0 - 10 需在報告中說明。

## 6. Deployment（部署）

將表現合宜的特徵選擇器與迴歸模型保存為 joblib Pipeline，未來可透過 Python 腳本、Streamlit 或 FastAPI 輸入理化指標得到預估品質分數。部署後需記錄資料版本、特徵名稱與模型版本，監測新資料分布漂移及預測誤差；如需部署預測區間，也須保存相對應的統計模型及特徵順序。

## 五、實作流程與完整 Python 程式

環境（本機或 Google Colab）：pip install pandas numpy matplotlib seaborn scikit-learn statsmodels joblib kagglehub。程式會使用 kagglehub 自動下載指定 Kaggle 資料集；若執行目錄已有 WineQT.csv，則優先使用本地檔案。獨立可執行版本為 7114056XXX\_hw2.py，可在 Colab 上先執行安裝指令，再上傳並執行該檔案。

### 程式產出

- ．01\_correlation\_heatmap.png：相關係數熱圖。
- ．02\_model\_metrics.csv：A、B、C 三個模型的 MAE / MSE / RMSE /  $R^2$ 。
- ．03\_prediction\_interval.png：實際品質 vs. 預測品質 + 95% Prediction Interval（題目必要）。
- ．04\_actual\_vs\_predicted.png：預測值與真實值散佈圖。
- ．三份 .joblib：訓練好的 pipeline。

避免誤解：03\_prediction\_interval.png 需下載 CSV 執行後才會生成；此份 Markdown 本身沒有宣稱已實際完成模型測試。程式使用 OLS 殘差估計傳統、模型假設成立下的參數式預測區間；區間涵蓋率仍需實際驗證。


## 六、結果表格（執行後填寫）


| 模型                  | 特徵數 | MAE    | MSE    | RMSE   | R <sup>2</sup> |
|---------------------|-----|--------|--------|--------|----------------|
| A：單變數 alcohol       | 1   | 0.5265 | 0.4175 | 0.6462 | 0.2497         |
| B：全部特徵              | 11  | 0.4773 | 0.3800 | 0.6165 | 0.3171         |
| C：SelectKBest top 5 | 5   | 0.4834 | 0.3856 | 0.6210 | 0.3071         |

本次執行結果顯示，全部 11 個特徵的模型表現最佳，RMSE 為 0.6165、R<sup>2</sup> 為 0.3171；相較只使用 alcohol 的基準模型，RMSE 下降約 4.6%，R<sup>2</sup> 由 0.2497 提升至 0.3171。SelectKBest 選出的 5 個特徵為 volatile\_acidity、citric\_acid、density、sulphates、alcohol，其 RMSE 為 0.6210，僅比全部特徵模型高 0.0045，表示使用較少變數仍保有接近的預測能力。模型 C 的 95% 預測區間涵蓋率為 0.9520，平均區間寬度為 2.5916。由於品質分數集中在 5 和 6，且樣本量為 1,143 筆，線性模型的 R<sup>2</sup> 仍有限；本結果適合作為可解釋基準，不宜視為取代感官品評的完整模型。

以上指標來自固定 random\_state=42 的 80/20 保留測試集；測試集只用於最後評估，沒有用來選擇特徵或調整模型。

## 實際圖表





## 七、GPT 輔助內容與 NotebookLM 摘要

### GPT 輔助內容

本報告使用 GPT 協助整理 CRISP-DM 架構、設計三組線性回歸比較、撰寫 KaggleHub 可重現下載程式、規劃 SelectKBest 特徵選擇，以及建立 OLS 95% 預測區間。所有模型指標與圖表均由 7114056XXX\_hw2.py 實際執行產生；GPT 未直接捏造實驗數字。GPT 對話紀錄應另以 pdfCrowd 或瀏覽器列印功能匯出 PDF，並與本報告一併繳交。

### GPT 對話摘要

本次對話先針對既有 Wine Quality 報告檢查作業要求，確認資料集必須具備 10 至 20 個特徵，並納入 CRISP-DM、特徵選擇、模型評估、預測圖與區間估計。接著將原本要求手動放置 WineQT.csv 的程式，改為使用 `kagglehub.dataset_download("yasserh/wine-quality-dataset")` 自動下載，並保留本地 CSV 作為 fallback。環境處理過程中，GPT 協助建立 Python 3.12 的 .venv，安裝 KaggleHub、pandas、NumPy、Matplotlib、Seaborn、scikit-learn、statsmodels 與 joblib。完成環境後，GPT 建立獨立的 7114056XXX\_hw2.py 與 Colab Notebook，實際下載 1,143 筆資料並執行三個模型。實驗結果顯示全部 11 特徵模型 RMSE 最低為 0.6165，SelectKBest 前 5 特徵模型的 RMSE 為 0.6210，95% 預測區間涵蓋率為 0.9520。最後，GPT 將結果、圖表、程式與報告整理成 PDF 與 ZIP。這段摘要描述的是實際協作與執行流程，完整對話紀錄另附 ilovepdf\_merged.pdf。

建議匯入下列來源再讓 NotebookLM 做交叉比對：

- Kaggle 原資料：<https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>
- UCI 資料與研究說明：<https://archive.ics.uci.edu/dataset/186/wine+quality>
- Kaggle 同資料之模型比較範例：<https://www.kaggle.com/code/yasserh/wine-quality-prediction-comparing-top-ml-models>
- 原始論文：Cortez et al. (2009), \*Modeling wine preferences by data mining from physicochemical properties\* (可從 UCI 頁面連結進入)

NotebookLM 摘要 (100 字以上)：葡萄酒品質預測通常以化學測量值作為輸入，並以感官品質評分作為輸出。UCI Wine Quality 與其 Kaggle 衍生資料包含固定酸度、揮發性酸度、檸檬酸、殘糖、氯化物、游離與總二氧化硫、密度、pH、硫酸鹽及酒精等十一項特徵，適合用於迴歸，也能依品質門檻轉為分類。主流流程會先以簡單模型建立基準，再比較多元線性回歸、正規化回歸或樹模型，並使用交叉驗證避免只依賴單次切分。線性回歸的優點是係數容易解釋，但品質分數是離散且分布不均的有序評分，可能違反常態與同質變異假設。因此，本研究使用 MAE、RMSE、 $R^2$ 、殘差檢查及預測區間涵蓋率共同評估，並將 SelectKBest

的特徵選擇限制在訓練集，避免資料洩漏。與只使用 alcohol 的基準相比，多元模型能納入酸度、密度與硫酸鹽等資訊，但仍應將結果視為初步品質估計，而非取代專業品評。此摘要應使用 NotebookLM 以本節列出的來源進行查核，並保存 NotebookLM 研究畫面或匯出檔作為附件證明。

## 主流或更優解法比較

Kaggle 上常見的比較會加入 Random Forest、Gradient Boosting、XGBoost 或其他集成模型。這些非線性模型可能捕捉特徵交互作用，預測準確度通常有機會高於線性回歸，但可解釋性與預測區間呈現較複雜。本作業選擇線性回歸作為透明基準，並以 SelectKBest 降低變數數量；若要延伸，可在訓練資料內使用 K-fold cross-validation 比較 Ridge、Random Forest 與 Gradient Boosting，再以獨立測試集做最後評估。

## 八、繳交檢查清單

- ． [x] 指定 Kaggle 公開資料集與原始來源
- ． [x] 11 個 features 的確認與欄位解釋
- ． [x] CRISP-DM 六階段
- ． [x] 特徵選擇、三種回歸模型、評估方案與完整繪圖程式
- ． [x] 使用 KaggleHub 實際下載 WineQT.csv 並執行
- ． [x] 將 02\_model\_metrics.csv 的真實指標填回第六節
- ． [x] 產生 03\_prediction\_interval.png 與其他圖表
- ． [x] 建立可在 Google Colab 執行的 7114056XXX\_hw2.py
- ． [ ] 如老師要求，實際使用 NotebookLM 研究並保存來源／引用截圖

## 參考資料

- ． Kaggle, Wine Quality Dataset. <https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>
- ． UCI Machine Learning Repository, Wine Quality. <https://archive.ics.uci.edu/dataset/186/wine+quality>
- ． Yasser H., Wine Quality Prediction — Comparing Top ML Models.  
<https://www.kaggle.com/code/yasserh/wine-quality-prediction-comparing-top-ml-models>
- ． Cortez, P., et al. (2009). \*Modeling wine preferences by data mining from physicochemical properties\*. Decision Support Systems.