

Wine Quality Dataset：線性回歸研究與 CRISP-DM 專題報告

撰寫日期：2026-10-08。此文件為研究規劃與可重現實驗程式；模型數字與圖片須實際執行程式後填入，不虛構實驗結果。

一、資料集資格與結論

- Kaggle：https://www.kaggle.com/datasets/yasserh/wine-quality-dataset
- 原始來源 UCI：https://archive.ics.uci.edu/dataset/186/wine+quality
- Kaggle 名次：不適用 (N/A)。此連結是 Kaggle Dataset 資料集頁面，不是 Kaggle Competition 競賽頁面，因此沒有官方排行榜、參賽隊伍或提交分數名次。Kaggle 頁面上的 views、downloads、Usability 分數及 Related Notebooks 的獎章，均不是本研究模型的競賽名次。
- Kaggle 下載檔案通常為 WineQT.csv，有 11 個理化輸入特徵、1 個輸出 quality，另可能有 Id 識別碼。Id 不可作為預測特徵。
- 符合 10 至 20 個 features 要求：11 個。注意：特徵選擇後的模型可以只使用部分特徵；資料集原始特徵數仍為 11。
- 品質分數 quality 為離散、有序分數，仍可作為線性回歸的數值目標，但預測可能超出實際分數範圍；報告須交代此限制。
- 單變數線性回歸與多元線性回歸皆可行。Auto Regression 自迴歸依賴時間順序，本資料非時間序列，不建議使用。

二、欄位與角色

欄位	角色	說明
fixed acidity	X	固定酸度
volatile acidity	X	揮發性酸度
citric acid	X	檸檬酸
residual sugar	X	殘糖
chlorides	X	氯化物
free sulfur dioxide	X	游離二氧化硫
total sulfur dioxide	X	總二氧化硫
density	X	密度
pH	X	酸鹼值
sulphates	X	硫酸鹽
alcohol	X	酒精濃度
quality	y	品質評分（目標）
Id（若存在）	排除	索引／識別碼，避免假相關

UCI 提供紅、白葡萄酒原始資料集（紅酒 1599 筆、白酒 4898 筆）；本次指定的 Kaggle WineQT.csv 為其衍生版本，資料筆數須以實際下載 CSV 為準，不應直接將 UCI 白酒的 4898 筆視為本 Kaggle 檔案筆數。

三、研究目的與假設

研究問題：能否依據葡萄酒的理化測量數值預測其感官品質分數？特徵篩選能否在減少輸入維度的同時維持預測準確性？

- H1：多元線性回歸優於只用 alcohol 的單變數線性回歸。
- H2：以訓練集進行統計特徵篩選後，能以較少變數得到具競爭力的測試誤差。
- 注意：H1、H2 為待驗證假設，不是研究結論。

四、CRISP-DM 六大階段

1. Business Understanding（商業理解）

酒商或品管單位希望在感官品評之前，根據可測得的化學指標進行初步品質估計，協助品質管理與分析。成功準則為低 MAE / RMSE、合理 R^2 ，以及可解釋且可使用的預測區間。不以此模型取代專業品酒評估。

2. Data Understanding（資料理解）

使用 head()、info()、describe()、缺失值檢查、重複值分析、品質分數分布、特徵相關性熱圖。核實實際 CSV 的筆數、欄位、資料型態與 quality 不均衡現象。檢查同一欄位極端值及共線性。

3. Data Preparation（資料準備）

移除 Id，設定 quality 為 y、其餘 11 欄為 X。以固定 random_state 進行 80/20 訓練與測試切分。不得在切分前依全體資料選特徵或標準化，避免資料洩漏。特徵篩選只在訓練集進行。若有缺失值，須先於訓練資料上擬合補值器（範例採 sklearn Pipeline）。重複樣本需檢查並交代處理策略，避免同一紀錄同時出現在訓練和測試資料。

4. Modeling（模型建立）

- ．模型 A：Simple Linear Regression；只用 alcohol 作為自變數。
- ．模型 B：Multiple Linear Regression；11 個理化特徵全部納入。
- ．模型 C：Feature Selection + Multiple Linear Regression；訓練集以 SelectKBest(f_regression, k=5) 選出 5 個特徵後建模。
- ．迴歸模型公式： $\text{quality_hat} = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$ 。
- ．k=5 是事先指定的可重現展示設定，不代表實證最優；若要調整 k，需在訓練資料內執行交叉驗證，不可偷看測試集。

5. Evaluation（模型評估）

評估保留測試集上的 MAE、MSE、RMSE、 R^2 ，搭配實際值與預測值散佈圖、殘差圖、95% 預測區間圖、預測區間涵蓋率與平均寬度。比較三個模型；特徵數與解釋力也是評估指標。對單筆未來葡萄酒分數，預測區間（Prediction Interval）比均值信賴區間（Confidence Interval）更符合題意；前者考慮單筆資料的不可預測變動，因此通常更寬。OLS 的經典區間假設包括線性形式、誤差常態與同質變異等，需檢視殘差。若區間超出 0 - 10 需在報告中說明。

6. Deployment（部署）

將表現合宜的特徵選擇器與迴歸模型保存為 joblib Pipeline，未來可透過 Python 腳本、Streamlit 或 FastAPI 輸入理化指標得到預估品質分數。部署後需記錄資料版本、特徵名稱與模型版本，監測新資料分布漂移及預測誤差；如需部署預測區間，也須保存相對應的統計模型及特徵順序。

五、實作流程與完整 Python 程式

環境（本機或 Google Colab）：pip install pandas numpy matplotlib seaborn scikit-learn statsmodels joblib kagglehub。程式會使用 kagglehub 自動下載指定 Kaggle 資料集；若執行目錄已有 WineQT.csv，則優先使用本地檔案。獨立可執行版本為 5115056030_hw2.py，可在 Colab 上先執行安裝指令，再上傳並執行該檔案。

程式產出

- ．01_correlation_heatmap.png：相關係數熱圖。
- ．02_model_metrics.csv：A、B、C 三個模型的 MAE / MSE / RMSE / R^2 。
- ．03_prediction_interval.png：實際品質 vs. 預測品質 + 95% Prediction Interval（題目必要）。
- ．04_actual_vs_predicted.png：預測值與真實值散佈圖。
- ．三份 .joblib：訓練好的 pipeline。

避免誤解：03_prediction_interval.png 需下載 CSV 執行後才會生成；此份 Markdown 本身沒有宣稱已實際完成模型測試。程式使用 OLS 殘差估計傳統、模型假設成立下的參數式預測區間；區間涵蓋率仍需實際驗證。

參考資料

- . Kaggle, Wine Quality Dataset. <https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>
- . UCI Machine Learning Repository, Wine Quality. <https://archive.ics.uci.edu/dataset/186/wine+quality>
- . Yasser H., Wine Quality Prediction — Comparing Top ML Models.
<https://www.kaggle.com/code/yasserh/wine-quality-prediction-comparing-top-ml-models>
- . Cortez, P., et al. (2009). *Modeling wine preferences by data mining from physicochemical properties*. Decision Support Systems.