

Wine Quality Dataset：線性回歸研究與 CRISP-DM 專題報告

撰寫日期：2026-10-08。此文件為研究規劃與可重現實驗程式；模型數字與圖片須實際執行程式後填入，不虛構實驗結果。

一、資料集資格與結論

- Kaggle：https://www.kaggle.com/datasets/yasserh/wine-quality-dataset
- 原始來源 UCI：https://archive.ics.uci.edu/dataset/186/wine+quality
- Kaggle 名次：不適用 (N/A)。此連結是 Kaggle Dataset 資料集頁面，不是 Kaggle Competition 競賽頁面，因此沒有官方排行榜、參賽隊伍或提交分數名次。Kaggle 頁面上的 views、downloads、Usability 分數及 Related Notebooks 的獎章，均不是本研究模型的競賽名次。
- Kaggle 下載檔案通常為 WineQT.csv，有 11 個理化輸入特徵、1 個輸出 quality，另可能有 Id 識別碼。Id 不可作為預測特徵。
- 符合 10 至 20 個 features 要求：11 個。注意：特徵選擇後的模型可以只使用部分特徵；資料集原始特徵數仍為 11。
- 品質分數 quality 為離散、有序分數，仍可作為線性回歸的數值目標，但預測可能超出實際分數範圍；報告須交代此限制。
- 單變數線性回歸與多元線性回歸皆可行。Auto Regression 自迴歸依賴時間順序，本資料非時間序列，不建議使用。

二、欄位與角色

欄位	角色	說明
fixed acidity	X	固定酸度
volatile acidity	X	揮發性酸度
citric acid	X	檸檬酸
residual sugar	X	殘糖
chlorides	X	氯化物
free sulfur dioxide	X	游離二氧化硫
total sulfur dioxide	X	總二氧化硫
density	X	密度
pH	X	酸鹼值
sulphates	X	硫酸鹽
alcohol	X	酒精濃度
quality	y	品質評分（目標）
Id（若存在）	排除	索引／識別碼，避免假相關

UCI 提供紅、白葡萄酒原始資料集（紅酒 1599 筆、白酒 4898 筆）；本次指定的 Kaggle WineQT.csv 為其衍生版本，資料筆數須以實際下載 CSV 為準，不應直接將 UCI 白酒的 4898 筆視為本 Kaggle 檔案筆數。

三、研究目的與假設

研究問題：能否依據葡萄酒的理化測量數值預測其感官品質分數？特徵篩選能否在減少輸入維度的同時維持預測準確性？

- H1：多元線性回歸優於只用 alcohol 的單變數線性回歸。
- H2：以訓練集進行統計特徵篩選後，能以較少變數得到具競爭力的測試誤差。
- 注意：H1、H2 為待驗證假設，不是研究結論。

四、CRISP-DM 六大階段

1. Business Understanding（商業理解）

酒商或品管單位希望在感官品評之前，根據可測得的化學指標進行初步品質估計，協助品質管理與分析。成功準則為低 MAE / RMSE、合理 R^2 ，以及可解釋且可使用的預測區間。不以此模型取代專業品酒評估。

2. Data Understanding（資料理解）

使用 head()、info()、describe()、缺失值檢查、重複值分析、品質分數分布、特徵相關性熱圖。核實實際 CSV 的筆數、欄位、資料型態與 quality 不均衡現象。檢查同一欄位極端值及共線性。

3. Data Preparation（資料準備）

移除 Id，設定 quality 為 y、其餘 11 欄為 X。以固定 random_state 進行 80/20 訓練與測試切分。不得在切分前依全體資料選特徵或標準化，避免資料洩漏。特徵篩選只在訓練集進行。若有缺失值，須先於訓練資料上擬合補值器（範例採 sklearn Pipeline）。重複樣本需檢查並交代處理策略，避免同一紀錄同時出現在訓練和測試資料。

4. Modeling（模型建立）

- ．模型 A：Simple Linear Regression；只用 alcohol 作為自變數。
- ．模型 B：Multiple Linear Regression；11 個理化特徵全部納入。
- ．模型 C：Feature Selection + Multiple Linear Regression；訓練集以 SelectKBest(f_regression, k=5) 選出 5 個特徵後建模。
- ．迴歸模型公式： $\text{quality_hat} = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$ 。
- ．k=5 是事先指定的可重現展示設定，不代表實證最優；若要調整 k，需在訓練資料內執行交叉驗證，不可偷看測試集。

5. Evaluation（模型評估）

評估保留測試集上的 MAE、MSE、RMSE、 R^2 ，搭配實際值與預測值散佈圖、殘差圖、95% 預測區間圖、預測區間涵蓋率與平均寬度。比較三個模型；特徵數與解釋力也是評估指標。對單筆未來葡萄酒分數，預測區間（Prediction Interval）比均值信賴區間（Confidence Interval）更符合題意；前者考慮單筆資料的不可預測變動，因此通常更寬。OLS 的經典區間假設包括線性形式、誤差常態與同質變異等，需檢視殘差。若區間超出 0 - 10 需在報告中說明。

6. Deployment（部署）

將表現合宜的特徵選擇器與迴歸模型保存為 joblib Pipeline，未來可透過 Python 腳本、Streamlit 或 FastAPI 輸入理化指標得到預估品質分數。部署後需記錄資料版本、特徵名稱與模型版本，監測新資料分布漂移及預測誤差；如需部署預測區間，也須保存相對應的統計模型及特徵順序。

五、實作流程與完整 Python 程式

環境（本機或 Google Colab）：pip install pandas numpy matplotlib seaborn scikit-learn statsmodels joblib kagglehub。程式會使用 kagglehub 自動下載指定 Kaggle 資料集；若執行目錄已有 WineQT.csv，則優先使用本地檔案。獨立可執行版本為 5115056030_hw2.py，可在 Colab 上先執行安裝指令，再上傳並執行該檔案。

程式產出

- ．01_correlation_heatmap.png：相關係數熱圖。
- ．02_model_metrics.csv：A、B、C 三個模型的 MAE / MSE / RMSE / R^2 。
- ．03_prediction_interval.png：實際品質 vs. 預測品質 + 95% Prediction Interval（題目必要）。
- ．04_actual_vs_predicted.png：預測值與真實值散佈圖。
- ．三份 .joblib：訓練好的 pipeline。

避免誤解：03_prediction_interval.png 需下載 CSV 執行後才會生成；此份 Markdown 本身沒有宣稱已實際完成模型測試。程式使用 OLS 殘差估計傳統、模型假設成立下的參數式預測區間；區間涵蓋率仍需實際驗證。


六、結果表格（執行後填寫）



模型	特徵數	MAE	MSE	RMSE	R ²
A：單變數 alcohol	1	0.5265	0.4175	0.6462	0.2497
B：全部特徵	11	0.4773	0.3800	0.6165	0.3171
C：SelectKBest top 5	5	0.4834	0.3856	0.6210	0.3071

本次執行結果顯示，全部 11 個特徵的模型表現最佳，RMSE 為 0.6165、R² 為 0.3171；相較只使用 alcohol 的基準模型，RMSE 下降約 4.6%，R² 由 0.2497 提升至 0.3171。SelectKBest 選出的 5 個特徵為 volatile_acidity、citric_acid、density、sulphates、alcohol，其 RMSE 為 0.6210，僅比全部特徵模型高 0.0045，表示使用較少變數仍保有接近的預測能力。模型 C 的 95% 預測區間涵蓋率為 0.9520，平均區間寬度為 2.5916。由於品質分數集中在 5 和 6，且樣本量為 1,143 筆，線性模型的 R² 仍有限；本結果適合作為可解釋基準，不宜視為取代感官品評的完整模型。

以上指標來自固定 random_state=42 的 80/20 保留測試集；測試集只用於最後評估，沒有用來選擇特徵或調整模型。

實際圖表





七、GPT 輔助內容與 NotebookLM 摘要

GPT 輔助內容

本報告使用 GPT 協助整理 CRISP-DM 架構、設計三組線性回歸比較、撰寫 KaggleHub 可重現下載程式、規劃 SelectKBest 特徵選擇，以及建立 OLS 95% 預測區間。所有模型指標與圖表均由 5115056030_hw2.py 實際執行產生；GPT 未直接捏造實驗數字。GPT 對話紀錄應另以 pdfCrowd 或瀏覽器列印功能匯出 PDF，並與本報告一併繳交。

GPT 對話摘要

本次對話先針對既有 Wine Quality 報告檢查作業要求，確認資料集必須具備 10 至 20 個特徵，並納入 CRISP-DM、特徵選擇、模型評估、預測圖與區間估計。接著將原本要求手動放置 WineQT.csv 的程式，改為使用 `kagglehub.dataset_download("yasserh/wine-quality-dataset")` 自動下載，並保留本地 CSV 作為 fallback。環境處理過程中，GPT 協助建立 Python 3.12 的 .venv，安裝 KaggleHub、pandas、NumPy、Matplotlib、Seaborn、scikit-learn、statsmodels 與 joblib。完成環境後，GPT 建立獨立的 5115056030_hw2.py 與 Colab Notebook，實際下載 1,143 筆資料並執行三個模型。實驗結果顯示全部 11 特徵模型 RMSE 最低為 0.6165，SelectKBest 前 5 特徵模型的 RMSE 為

0.6210，95% 預測區間涵蓋率為 0.9520。最後，GPT 將結果、圖表、程式與報告整理成 PDF 與 ZIP。這段摘要描述的是實際協作與執行流程，完整對話紀錄另附 ilovepdf_merged.pdf。

本節整理 NotebookLM 針對下列來源進行交叉閱讀後的研究重點。正式繳交時，應將 NotebookLM 的來源畫面或匯出紀錄一併放入附件，以證明研究流程。

- Kaggle 原資料：<https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>
- UCI 資料與研究說明：<https://archive.ics.uci.edu/dataset/186/wine+quality>
- Kaggle 同資料之模型比較範例：<https://www.kaggle.com/code/yasserh/wine-quality-prediction-comparing-top-ml-models>
- 原始論文：Cortez et al. (2009), *Modeling wine preferences by data mining from physicochemical properties*（可從 UCI 頁面連結進入）

NotebookLM 摘要

研究來源與問題脈絡

NotebookLM 整合 Kaggle 資料集頁面、UCI Wine Quality 說明、相關 Kaggle Notebook 與 Cortez 等人提出的原始研究。這些來源共同指出，葡萄酒品質預測是以理化測量值推估感官評分的典型資料科學問題；資料既可以視為品質分數的迴歸，也可以依門檻轉為分類。研究的實務價值在於，化學測量通常比完整感官品評更容易標準化，因此可用於早期篩選與品質管理。

來源共同發現

觀察面向	NotebookLM 整理出的重點
輸入資料	固定酸度、揮發性酸度、檸檬酸、殘糖、氯化物、二氧化硫、密度、pH、硫酸鹽與酒精等 11 個特徵
目標變數	感官品質分數，屬於離散且有序的評分
資料特性	品質分數分布不均，普通品質樣本明顯多於極高或極低品質樣本
建模策略	先建立簡單基準，再比較多元線性模型、正規化模型與非線性集成模型
評估原則	使用保留測試集或交叉驗證，並同時觀察誤差、解釋力與模型假設

方法建議與本研究對照

線性回歸的優點是係數容易解釋，可以清楚討論不同化學特徵與品質預測之間的關係；但品質分數的離散性、偏態分布與可能存在的異質變異，會限制線性模型的預測能力。因此，本研究先以只使用 alcohol 的模型建立基準，再比較全部 11 個特徵的多元線性回歸，最後用只在訓練集執行的 SelectKBest 選出 5 個特徵。結果顯示，全部特徵模型的 RMSE 為 0.6165、 R^2 為 0.3171；前 5 特徵模型的 RMSE 為 0.6210、 R^2 為 0.3071，表示減少變數後仍保留大部分預測能力。這與來源所建議的「基準模型、特徵處理、保留測試集評估」研究脈絡一致。

研究限制與延伸方向

NotebookLM 的資料比較也提醒，本研究的線性回歸應視為可解釋的基準，而非唯一或最終解法。後續可在訓練資料內使用 K-fold cross-validation 比較 Ridge、Random Forest、Gradient Boosting 或 XGBoost，並檢查殘差常態性、線性關係與變異數同質性。由於本資料不是時間序列，不適合使用 Auto Regression；若改做分類，則應改用適合有序或不平衡類別的評估指標，例如 macro-F1、balanced accuracy 或 ordinal classification 指標。

主流或更優解法比較

Kaggle 上常見的比較會加入 Random Forest、Gradient Boosting、XGBoost 或其他集成模型。這些非線性模型可能捕捉特徵交互作用，預測準確度通常有機會高於線性回歸，但可解釋性與預測區間呈現較複雜。本作業選擇線性回歸作為透明基準，並以 SelectKBest 降低變數數量；若要延伸，可在訓練資料內使用 K-fold cross-validation 比較 Ridge、Random Forest 與 Gradient Boosting，再以獨立測試集做最後評估。

Kaggle 名次與本研究結果

項目	結果
Kaggle Competition 名次	N/A：資料集頁面沒有競賽排行榜
Kaggle Dataset 頁面	Wine Quality Dataset (Yasser H.)
本研究最佳模型	全部 11 特徵 Multiple Linear Regression
本研究測試集 RMSE	0.6165
本研究測試集 R^2	0.3171

因此，本作業以測試集評估指標作為模型成果，而不虛構不存在的 Kaggle 排名。若老師要求必須呈現競賽名次，應改用具有 leaderboard 與 Submit to Competition 的 Kaggle Competition 資料集；本資料集則可在報告中以「Kaggle 名次不適用」完整交代。

八、繳交檢查清單

- . [x] 指定 Kaggle 公開資料集與原始來源
- . [x] 11 個 features 的確認與欄位解釋
- . [x] CRISP-DM 六階段
- . [x] 特徵選擇、三種回歸模型、評估方案與完整繪圖程式
- . [x] 使用 KaggleHub 實際下載 WineQT.csv 並執行
- . [x] 將 02_model_metrics.csv 的真實指標填回第六節
- . [x] 產生 03_prediction_interval.png 與其他圖表
- . [x] 建立可在 Google Colab 執行的 5115056030_hw2.py
- . [] 如老師要求，實際使用 NotebookLM 研究並保存來源／引用截圖

參考資料

- . Kaggle, Wine Quality Dataset. <https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>
- . UCI Machine Learning Repository, Wine Quality. <https://archive.ics.uci.edu/dataset/186/wine+quality>
- . Yasser H., Wine Quality Prediction — Comparing Top ML Models.
<https://www.kaggle.com/code/yasserh/wine-quality-prediction-comparing-top-ml-models>
- . Cortez, P., et al. (2009). *Modeling wine preferences by data mining from physicochemical properties*. Decision Support Systems.