

# GPT 輔助內容

## 本次對話與葡萄酒品質資料集研究報告

日期：2026-10-08

### 對話紀錄（本次請求與回覆摘要）

**使用者：**評估 <https://www.kaggle.com/datasets/yasserh/wine-quality-dataset> 是否符合 10~20 個特徵，使用線性回歸並包含特徵選擇、模型評估、預測圖與信賴／預測區間，涵蓋 CRISP-DM 六階段；整理 Markdown，並將對話存成 PDF。

**助理：**確認指定資料具有 11 個理化輸入特徵，quality 是目標變數，Id 不是有效特徵。建議比較單一與多元線性回歸及特徵選擇版本，提供具 95% 預測區間繪圖的完整程式。實際實驗指標和圖片必須執行程式後才能填寫。

註：本 PDF 保存這次任務的對話摘要和完整研究報告，不是平台的逐字對話匯出。

---

## Wine Quality Dataset：線性回歸研究與 CRISP-DM 專題報告

撰寫日期：2026-10-08。此文件為研究規劃與可重現實驗程式；模型數字與圖片須實際執行程式後填入，不虛構實驗結果。

### 一、資料集資格與結論

- Kaggle：<https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>
- 原始來源 UCI：<https://archive.ics.uci.edu/dataset/186/wine+quality>
- Kaggle 下載檔案通常為 WineQT.csv，有 11 個理化輸入特徵、1 個輸出 quality，另可能有 Id 識別碼。Id 不可作為預測特徵。
- **符合 10 至 20 個 features 要求：11 個。**注意：特徵選擇後的模型可以只使用部分特徵；資料集原始特徵數仍為 11。
- 品質分數 quality 為離散、有序分數，仍可作為線性回歸的數值目標，但預測可能超出實際分數範圍；報告須交代此限制。

- 單變數線性回歸與多元線性回歸皆可行。Auto Regression 自迴歸依賴時間順序，本資料非時間序列，不建議使用。

## 二、欄位與角色

| 欄位                   | 角色 | 說明           |
|----------------------|----|--------------|
| fixed acidity        | X  | 固定酸度         |
| volatile acidity     | X  | 揮發性酸度        |
| citric acid          | X  | 檸檬酸          |
| residual sugar       | X  | 殘糖           |
| chlorides            | X  | 氯化物          |
| free sulfur dioxide  | X  | 游離二氧化硫       |
| total sulfur dioxide | X  | 總二氧化硫        |
| density              | X  | 密度           |
| pH                   | X  | 酸鹼值          |
| sulphates            | X  | 硫酸鹽          |
| alcohol              | X  | 酒精濃度         |
| quality              | y  | 品質評分（目標）     |
| Id（若存在）              | 排除 | 索引／識別碼，避免假相關 |

UCI 提供紅、白葡萄酒原始資料集（紅酒 1599 筆、白酒 4898 筆）；**本次指定的 Kaggle WineQT.csv 為其衍生版本，資料筆數須以實際下載 CSV 為準，不應直接將 UCI 白酒的 4898 筆視為本 Kaggle 檔案筆數。**

## 三、研究目的與假設

研究問題：能否依據葡萄酒的理化測量數值預測其感官品質分數？特徵篩選能否在減少輸入維度的同時維持預測準確性？

- H1：多元線性回歸優於只用 alcohol 的單變數線性回歸。
- H2：以訓練集進行統計特徵篩選後，能以較少變數得到具競爭力的測試誤差。
- 注意：H1、H2 為**待驗證假設**，不是研究結論。

## 四、CRISP-DM 六大階段

### 1. Business Understanding（商業理解）

酒商或品管單位希望在感官品評之前，根據可測得的化學指標進行初步品質估計，協助品質管理與分析。成功準則為低 MAE / RMSE、合理  $R^2$ ，以及可解釋且可使用的預測區間。不以此模型取代專業品酒評估。

## 2. Data Understanding (資料理解)

使用 `head()`、`info()`、`describe()`、缺失值檢查、重複值分析、品質分數分布、特徵相關性熱圖。核實實際 CSV 的筆數、欄位、資料型態與 `quality` 不均衡現象。檢查同一欄位極端值及共線性。

## 3. Data Preparation (資料準備)

移除 `Id`，設定 `quality` 為 `y`、其餘 11 欄為 `X`。以固定 `random_state` 進行 80/20 訓練與測試切分。不得在切分前依全體資料選特徵或標準化，避免資料洩漏。特徵篩選只在訓練集進行。若有缺失值，須先於訓練資料上擬合補值器（範例採 `sklearn Pipeline`）。重複樣本需檢查並交代處理策略，避免同一紀錄同時出現在訓練和測試資料。

## 4. Modeling (模型建立)

- 模型 A：Simple Linear Regression；只用 `alcohol` 作為自變數。
- 模型 B：Multiple Linear Regression；11 個理化特徵全部納入。
- 模型 C：Feature Selection + Multiple Linear Regression；訓練集以 `SelectKBest(f_regression, k=5)` 選出 5 個特徵後建模。
- 迴歸模型公式： $\text{quality\_hat} = \beta_0 + \beta_1 \times x_1 + \dots + \beta_p \times x_p$ 。
- `k=5` 是事先指定的可重現展示設定，不代表實證最優；若要調整 `k`，需在訓練資料內執行交叉驗證，不可偷看測試集。

## 5. Evaluation (模型評估)

評估保留測試集上的 `MAE`、`MSE`、`RMSE`、 $R^2$ ，搭配實際值與預測值散佈圖、殘差圖、95% 預測區間圖、預測區間涵蓋率與平均寬度。比較三個模型；特徵數與解釋力也是評估指標。對單筆未來葡萄酒分數，**預測區間 (Prediction Interval) 比均值信賴區間 (Confidence Interval) 更符合題意**；前者考慮單筆資料的不可預測變動，因此通常更寬。OLS 的經典區間假設包括線性形式、誤差常態與同質變異等，需檢視殘差。若區間超出 0-10 需在報告中說明。

## 6. Deployment (部署)

將表現合宜的特徵選擇器與迴歸模型保存為 `joblib Pipeline`，未來可透過 Python 腳本、`Streamlit` 或 `FastAPI` 輸入理化指標得到預估品質分數。部署後需記錄資料版本、特徵名稱與模型版本，監測新資料分布漂移及預測誤差；如需部署預測區間，也須保存相對應的統計模型及特徵順序。

## 五、實作流程與完整 Python 程式

環境：pip install pandas numpy matplotlib seaborn scikit-learn statsmodels joblib。將 Kaggle 下載的 WineQT.csv 放在程式執行目錄。程式不需要額外資料集。

```
from pathlib import Path
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import joblib
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.feature_selection import SelectKBest, f_regression
from sklearn.linear_model import LinearRegression
from sklearn.impute import SimpleImputer
from sklearn.pipeline import Pipeline
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

PATH = Path("WineQT.csv")
if not PATH.exists():
    raise FileNotFoundError("請從指定 Kaggle 網址下載 WineQT.csv 並放在同一資料夾")

df = pd.read_csv(PATH)
df.columns = df.columns.str.strip().str.replace(" ", "_", regex=False)
print("資料維度: ", df.shape)
print("欄位: ", df.columns.tolist())
print("缺失值: \n", df.isna().sum())
print("quality 分布: \n", df["quality"].value_counts().sort_index())

# 此 Kaggle CSV 可能有 Id; 明確移除識別碼。
df = df.drop(columns=["Id", "id"], errors="ignore")
X = df.drop(columns=["quality"])
y = df["quality"]
assert X.shape[1] == 11, f"預期 11 個輸入特徵, 實際 {X.shape[1]}。請檢查檔案。"
assert "alcohol" in X.columns

plt.figure(figsize=(10, 8))
sns.heatmap(df.corr(numeric_only=True), cmap="coolwarm", center=0)
plt.title("Feature correlation")
plt.tight_layout()
plt.savefig("01_correlation_heatmap.png", dpi=180)
plt.close()

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=42
)

models = {
    "A_Simple_alcohol": (["alcohol"], Pipeline([
        ("imputer", SimpleImputer(strategy="median")),
        ("reg", LinearRegression())
    ])),
    "B_Multiple_all11": (list(X.columns), Pipeline([
        ("imputer", SimpleImputer(strategy="median")),
        ("reg", LinearRegression())
    ])),
    "C_Selected_top5": (list(X.columns), Pipeline([
        ("imputer", SimpleImputer(strategy="median")),
        ("select", SelectKBest(score_func=f_regression, k=5)),
        ("reg", LinearRegression())
    ]))
}

results = []
for name, (columns, model) in models.items():
    model.fit(X_train[columns], y_train)
    prediction = model.predict(X_test[columns])
    mse = mean_squared_error(y_test, prediction)
    selected_cols = columns
    if name == "C_Selected_top5":
        selected_cols = X_train[columns].columns[
            model.named_steps["select"].get_support()
        ].tolist()
    results.append({
        "Model": name,
        "Features": " ".join(selected_cols),
    })
```

```

        "N_features": len(selected_cols),
        "MAE": mean_absolute_error(y_test, prediction),
        "MSE": mse,
        "RMSE": np.sqrt(mse),
        "R2": r2_score(y_test, prediction)
    })
    joblib.dump(model, f"{name}.joblib")

metrics = pd.DataFrame(results).sort_values("RMSE")
print(metrics.to_string(index=False))
metrics.to_csv("02_model_metrics.csv", index=False, encoding="utf-8-sig")

# 以事先指定的模型 C 製作 95% 單筆預測區間（不依測試成績挑模型）。
selected_pipe = models["C_Selected_top5"][1]
selector = selected_pipe.named_steps["select"]
selected_names = X_train.columns[selector.get_support()].tolist()
imputer = selected_pipe.named_steps["imputer"]
tr_array = imputer.transform(X_train)
te_array = imputer.transform(X_test)
tr_selected = selector.transform(tr_array)
te_selected = selector.transform(te_array)

# 在訓練集上以相同欄位重新擬合 OLS，取得統計推論的預測區間。
X_ols_train = sm.add_constant(tr_selected, has_constant="add")
X_ols_test = sm.add_constant(te_selected, has_constant="add")
ols = sm.OLS(y_train.to_numpy(), X_ols_train).fit()
frame = ols.get_prediction(X_ols_test).summary_frame(alpha=0.05)

# 排序只是為了使圖易讀，區間仍是對每一個測試樣本的估計。
idx = np.argsort(frame["mean"].to_numpy())
actual = y_test.to_numpy()[idx]
pred = frame["mean"].to_numpy()[idx]
lower = frame["obs_ci_lower"].to_numpy()[idx]
upper = frame["obs_ci_upper"].to_numpy()[idx]
xaxis = np.arange(len(idx))

plt.figure(figsize=(13, 6))
plt.fill_between(xaxis, lower, upper, alpha=0.28, label="95% prediction interval")
plt.plot(xaxis, pred, linewidth=1.6, label="Predicted quality")
plt.scatter(xaxis, actual, s=12, alpha=0.6, label="Actual quality")
plt.xlabel("Test samples (sorted by prediction)")
plt.ylabel("Quality score")
plt.title("Selected Linear Regression: Prediction with 95% PI")
plt.legend()
plt.tight_layout()
plt.savefig("03_prediction_interval.png", dpi=200)
plt.close()

plt.figure(figsize=(7, 6))
plt.scatter(y_test, frame["mean"], alpha=0.5)
lims = [min(y_test.min(), frame["mean"].min()),
        max(y_test.max(), frame["mean"].max())]
plt.plot(lims, lims, "r--", label="Ideal")
plt.xlabel("Actual quality")
plt.ylabel("Predicted quality")
plt.title("Actual vs Predicted (Selected Linear Regression)")
plt.legend()
plt.tight_layout()
plt.savefig("04_actual_vs_predicted.png", dpi=200)
plt.close()

coverage = np.mean((y_test.to_numpy() >= frame["obs_ci_lower"].to_numpy()) &
                  (y_test.to_numpy() <= frame["obs_ci_upper"].to_numpy()))
print("模型 C 選入特徵：", selected_names)
print("95% PI 實際涵蓋率：", round(coverage, 4))
print("PI 平均寬度：", round(np.mean(upper-lower), 4))
print("輸出圖片：01_correlation_heatmap.png、03_prediction_interval.png、04_actual_vs_predicted.png")

```

## 程式產出

- 01\_correlation\_heatmap.png：相關係數熱圖。
- 02\_model\_metrics.csv：A、B、C 三個模型的 MAE / MSE / RMSE /  $R^2$ 。
- 03\_prediction\_interval.png：實際品質 vs. 預測品質 + 95% Prediction Interval（題目必要）。
- 04\_actual\_vs\_predicted.png：預測值與真實值散佈圖。

# NotebookLM 摘要

本報告彙整當前網路上與學術界針對葡萄酒品質預測（Wine Quality Prediction）之主流實作路徑。目前網路上的解法多以 UCI Wine Quality Dataset 為基礎，將 11 項理化特徵（如酒精濃度、揮發性酸度、pH 值與硫酸鹽等）作為輸入變數，並區分為「回歸連續預測」與「品質等級分類」兩種方向。在資料預處理方面，常見做法包含特徵標準化（StandardScaler）與針對極端品質樣本進行重採樣（如 SMOTE）以解決類別不平衡問題。在特徵選擇上，主流透過遞歸特徵消除（RFE）、主成分分析（PCA）或相關係數熱力圖，選出影響最顯著的理化指標。在模型選用上，除基礎線性回歸外，多數網路解法亦延伸至非線性機器學習模型（如隨機森林 RF、支持向量機 SVM 與 XGBoost），實驗結果普遍顯示非線性模型與特徵篩選結合後能大幅提升預測準率與模型穩定度。

## 核心發現與主題整理

- 多元建模視角：網路上解法涵蓋傳統線性回歸（連續得分預測）與機器學習分類器（將品質分為高/中/低等級），滿足不同場景的需求。
- 特徵篩選效益顯著：根據 PMC 與 SciTePress 發表的近期研究，透過 RFE 或 PCA 適當剔除低相關性特徵，能顯著降低噪訊並增強 SVM 與隨機森林等模型的預測穩定度。
- 資料不平衡處理：根據 arXiv 與 RPubs 的專案經驗，極端高低品質葡萄酒樣本稀少，採用特徵縮放與重採樣技術能有效提升模型對關鍵樣本的辨識力。